Rapport de Projet de Compilation Partie Backend

Rémi DESTIGNY - Isaline LAURENT

21 janvier 2012

Introduction

Un compilateur est généralement composé de deux parties, appelées FrontEnd et BackEnd. A partir d'un certain langage, ici proche du C, le FrontEnd retranscrit le code d'entrée en une forme intermédiaire. Ensuite, le BackEnd utilise ce code intermédiaire pour à nouveau le traduire en langage Assembleur.

Notre partie du projet concerne le BackEnd. Le code que nous devons traiter a donc plusieurs caractéristiques :

- C'est un code deux adresses. Les opérations se font donc avec des instructions comme += ou -=.
- Les seules boucles autorisées sont effectuées à partir de goto et de label.
 Les structures de plus haut niveau telles que while, sont prohibées.
- Les structures conditionnelles sont simplifiées. Il n'y a pas de clause else.
- Comme en C, on pourra traiter des bloc d'instructions et des fonctions.

Notre but principal est de traduire le code donné en assembleur x86 pour machine Intel en 32 bits. La vérification du type des variables est traité dans le FrontEnd et ne nous concerne pas.

1 Table de symboles

Avant de rentrer dans le vif du sujet, il est important de spécifier comment chaque identifiant est géré.

Deux choses nous ont poussés à implémenter une telle structure :

- Dans un premier temps, les variables étant stockées dans la pile, on va avoir besoin de connaître leur position pour pouvoir y accéder. A chaque symbole sera donc associé un offset.
- Ensuite, lorsque l'on a plusieurs fonctions, les variables ne sont pas forcément visibles dans chaque bloc. Il va donc être nécessaire d'établir un arbre de table de symboles, où chaque nœud est propre à une fonction, et n'a de visibilité que dans sa propre liste de symboles et la table racine.

La grammaire n'acceptant pas la déclaration de variables au milieu du code, les blocs d'instructions autre que des fonctions (if, goto...) n'ont pas de table propre.

Structures

Pour gérer cette structure, nous utilisons trois structures en terme de programmation C.

Tout d'abord, une structure pour décrire chaque nœud de l'arbre, c'est à dire chaque table.

```
struct symbolTableTreeNode
{
   struct symbolTableTreeNodeList* sons;
   struct symbolTableTreeNode* father;
   struct symbolTableIdentifierList* identifierList;
   char* functionName;
   struct string* code;
   int currentOffset;
   int parameterSize;
};
```

Elle est composée d'un champ father, et d'un champ sons pour respecter la navigation dans l'arbre. Le champ identifierList correspond aux symboles en eux-même. Il s'agit d'une liste, functionName et parameterSize sont des champs qui décrivent la fonction, c'est à dire son nom, et la taille de ses paramètres, code permet de gérer l'affichage du code asm. currentOffset correspond au FramePointer et permet de définir le début de la fonction dans la pile, et donc sa visibilité.

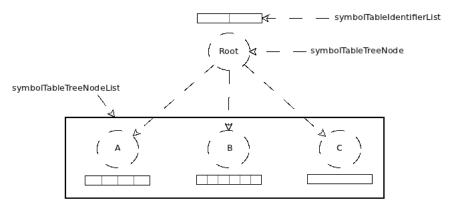
La structure qui suit décrit un étage de l'arbre. Il s'agit d'une liste de tables des symboles situés à la même distance de la racine.

```
struct symbolTableTreeNodeList
{
   struct symbolTableTreeNodeList* next;
   struct symbolTableTreeNode* data;
};
   Enfin, voici la liste des symboles en elle-même.
struct symbolTableIdentifierList
{
   struct symbolTableIdentifierList* next;
   char* name;
   int type;
   int offset;
   int size;
```

```
int nbArrayDimension;
int dimensionSizes[256];
};
```

Elle contient bien évidemment un pointeur vers l'élément suivant. Elle contient de plus toutes les informations concernant un symbole, c'est à dire son nom, son type, son offset (sa position dans la pile), et sa taille. Dans le cas d'un tableau, elle possède aussi sa dimension, et la taille de chacun des vecteurs qui le composent.

Graphiquement, nous avons donc le système qui suit :



Ici, Root a pour father NULL, et pour sons A, B et C. Les table A, B et C ont toutes pour père Root, et pas de fils. Root a deux éléments dans sa table des symboles, A quatre, B six et C un seul.